

Atividade Prática: Segmentação de Clientes com Aprendizado Não Supervisionado

Contexto e Objetivo

Esta atividade prática foca na aplicação de técnicas de clusterização para identificar nichos de clientes e analisar seu impacto nas finanças e estratégias de marketing de uma empresa. Você desenvolverá uma solução completa de segmentação de clientes utilizando dados reais de e-commerce, demonstrando competência técnica em machine learning não supervisionado e capacidade de traduzir resultados analíticos em insights de negócios acionáveis. [GeeksforGeeks +2](#)

Dataset Recomendado

Opção Principal: UCI Online Retail Dataset

- **Fonte:** <https://archive.ics.uci.edu/dataset/352/online+retail>
- **Registros:** 541.909 transações [uci](#) (Dez 2010 - Dez 2011) [UCI Machine Learning Repository](#)
- **Variáveis:** CustomerID, InvoiceDate, Quantity, UnitPrice, StockCode, Description, Country [uciUCI Machine Learning Repository](#)
- **Aplicação:** Perfeito para análise RFM (Recency, Frequency, Monetary) e segmentação baseada em valor [Prospectsoft +3](#)

Opção Avançada: Brazilian E-Commerce Olist Dataset

- **Fonte:** <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- **Registros:** ~100.000 pedidos com múltiplas tabelas relacionais [MediumGitHub](#)
- **Variáveis:** payment_value, freight_value, review_score, customer_location, product_category
- **Aplicação:** Permite análise multidimensional incluindo aspectos geográficos e comportamentais

Estrutura da Atividade com 5 Itens de Avaliação

Item 1: Implementação e Comparação de Algoritmos

Algoritmos Obrigatórios:

1. **K-Means Clustering**
 - Implementação com scikit-learn [scikit-learn +2](#)

- Determinação do k ótimo usando Elbow Method e Silhouette Score [Barilliance +6](#)
- Análise de convergência e estabilidade [Mit](#)

2. Hierarchical Clustering

- Agglomerative clustering com diferentes linkage methods (ward, complete, average) [Towards Data Science +4](#)
- Criação e interpretação de dendrograma [Towards Data Science +2](#)
- Corte ótimo da árvore hierárquica [Analytics Vidhya](#)

3. DBSCAN ou Gaussian Mixture Models

- Para DBSCAN: determinação de eps usando k-distance graph [Towards Data ScienceMedium](#)
- Para GMM: seleção de componentes usando BIC/AIC [mdpi](#)
- Tratamento de pontos de ruído ou probabilidades de pertencimento [freeCodeCampHex](#)

Código Esperado:

python

Exemplo de estrutura para comparação

```
from sklearn.cluster import KMeans, AgglomerativeClustering, DBSCAN
```

```
from sklearn.metrics import silhouette_score, davies_bouldin_score
```

Dicionário para armazenar resultados

```
resultados = {
    'algoritmo': [],
    'n_clusters': [],
    'silhouette': [],
    'davies_bouldin': [],
    'tempo_execução': []
}
```

Implementar cada algoritmo e coletar métricas

Critérios de Avaliação:

- Implementação correta dos 3 algoritmos
- Uso apropriado de métricas de validação
- Otimização de hiperparâmetros justificada
- Análise comparativa quantitativa (4 pts)

Item 2: Visualização e Interpretação de Clusters (25 pontos)

Visualizações Obrigatórias:

1. Scatter Plot com PCA (2D e 3D)

- Redução dimensional preservando 80%+ da variância [scikit-learn](#)
- Coloração por cluster com centroides marcados
- Interpretação dos componentes principais [Medium](#)

2. Perfil de Clusters - Radar Chart

python

Estrutura esperada

```
import plotly.graph_objects as go
```

```
fig = go.Figure()
```

```
for cluster in range(n_clusters):
```

```
    fig.add_trace(go.Scatterpolar(
```

```
        r=cluster_means[cluster],
```

```
        theta=features,
```

```
        name=f'Cluster {cluster}'
```

```
    ))
```

3. Heatmap de Características por Cluster

- Valores normalizados das features por segmento [Seaborn](#)
- Identificação visual de padrões distintivos
- Anotações com valores médios

4. Distribuição de Valor por Segmento

- Gráfico de barras: número de clientes por cluster
- Box plot: distribuição de valor monetário por cluster
- Gráfico de pizza: contribuição de revenue por segmento

Interpretação de Negócios:

- Nomear cada cluster baseado em características dominantes
 - Exemplos: "Champions", "At Risk", "New Customers", "Lost" [Medium](#)
- Descrever perfil comportamental de cada segmento
- Identificar segmentos de maior valor e maior risco

CrITÉrios de Avaliação:

- Qualidade técnica das visualizações
- Variedade e adequação dos gráficos
- Clareza na interpretação de negócios
- Nomeação significativa dos clusters

Item 3: Relatório Executivo e Recomendações

Estrutura do Relatório (máximo 1500 palavras):

1. **Sumário Executivo** (200 palavras)
 - Principais descobertas em bullets
 - Top 3 recomendações prioritárias
2. **Metodologia** (300 palavras)
 - Justificativa da escolha do algoritmo final
 - Limitações identificadas e mitigações
 - Validação dos resultados
3. **Resultados e Insights** (500 palavras)
 - Descrição dos segmentos identificados [Amazon](#)
 - Insights comportamentais principais [Accuratedigitalsolutions](#)
 - Oportunidades de negócio descobertas

Apresentação Visual:

- Dashboard interativo em Plotly ou Streamlit [Baremetrics](#)
- Jupyter Notebook documentado e reproduzível
- Código versionado em GitHub

Critérios de Avaliação:

- Clareza e concisão na comunicação
- Adequação ao público executivo
- Viabilidade das recomendações
- Qualidade da documentação técnica

Recursos e Bibliotecas Recomendadas

Bibliotecas Python Essenciais:

python

Processamento de dados

import pandas as pd

import numpy as np

Clustering

from sklearn.cluster import KMeans, AgglomerativeClustering, DBSCAN

from sklearn.mixture import GaussianMixture

from sklearn.preprocessing import StandardScaler, RobustScaler

Validação

from sklearn.metrics import silhouette_score, davies_bouldin_score

from sklearn.metrics import calinski_harabasz_score

Visualização

import matplotlib.pyplot as plt

import seaborn as sns

```
import plotly.express as px  
import plotly.graph_objects as go
```

```
# Redução dimensional
```

```
from sklearn.decomposition import PCA
```

```
from sklearn.manifold import TSNE
```

Métricas de Validação de Clusters:

1. **Silhouette Score:** -1 a 1 (quanto maior, melhor) [BarillianceWikipedia](#)
2. **Davies-Bouldin Index:** ≥ 0 (quanto menor, melhor) [scikit-learn](#)
3. **Calinski-Harabasz Index:** quanto maior, melhor [GeeksforGeeks](#)
4. **Inércia (Within-Cluster Sum of Squares):** para Elbow Method [WikipediaMedium](#)

Framework de Interpretação de Negócios:

Segmentação RFM Clássica:

- **Champions (555):** Clientes ideais, alto valor e engajamento [Analytics Vidhya +2](#)
- **Loyal Customers (X4X):** Compradores frequentes e consistentes [MediumCleverTap](#)
- **At Risk (2XX):** Clientes valiosos com risco de churn [MediumCleverTap](#)
- **New Customers (5X1):** Recém-chegados com potencial [MediumCleverTap](#)
- **Lost (1XX):** Clientes inativos necessitando reativação [MediumCleverTap](#)

Cronograma e Entregáveis

15/0

CrITÉRIOS de Excelência

Para alcançar nota máxima (100 pontos), o trabalho deve demonstrar:

- **Rigor Técnico:** Implementação correta com justificativas metodológicas
- **Pensamento Crítico:** Análise de trade-offs e limitações
- **Aplicação Prática:** Conexão clara com objetivos de negócio [Prospectsoft](#)

- **Comunicação Efetiva:** Visualizações claras e narrativa convincente
[FasterCapital](#)
- **Inovação:** Features criativas ou abordagens diferenciadas