

Aprendizado de Máquina Não Supervisionado

Relatório Atividade 1 - Segmentação de Clientes RFM

Gustavo Martins Conceição

1. Sumário Executivo

Projeto Desenvolvido utilizando o Dataset UCI Online Retail([Online Retail - UCI Machine Learning Repository](#)), contendo transações entre 01/12/2010 e 09/12/2011 de um varejista online localizado no Reino Unido. A análise RFM (Recency, Frequency, Monetary) segmentou a base de 4.251 clientes em 5 grupos comportamentais usando o algoritmo K-Means. Entre as descobertas, estão:

- Champions são apenas 13,9% da base (589 clientes) mas geram 50,6% da receita (£3,05M).
- At Risk é o segundo maior bloco de receita (23,8%, £1,44M) e o segundo maior em clientes (24,4%), mas já está com alto intervalo entre compras (~100 dias sem comprar).
- Lost e New Customers somam 44,5% dos clientes, mas apenas 9,5% da receita.
- Loyal Customers (17,2% dos clientes, 16,1% da receita) são a base mais estável e recente do negócio, com bom potencial de upsell.

Top 3 recomendações prioritárias:

- Campanha de reativação com prazo curto para At Risk.
- Programa VIP/fidelidade para Champions para proteger a metade da receita concentrada em 14% da base.
- Onboarding para New Customers, convertendo antes que migrem para "Lost".

2. Metodologia

2.1 Pipeline

Feita a limpeza de transações inválidas (sem CustomerID, cancelamentos, quantidades/preços não positivos). Para que então seja realizado o cálculo de RFM por cliente e a remoção de outliers extremos de Monetary (percentis 1%–99%) e log1p nas três variáveis e então é realizada a padronização com RobustScaler.

2.2 Escolha do algoritmo final

Os três algoritmos exigidos foram implementados e comparados (silhouette, Davies-Bouldin, Calinski-Harabasz, tempo de execução, conforme *comparacao_algoritmos.csv*). K-Means (k=5) foi escolhido por entregar qualidade equivalente ao Hierárquico (silhouette 0,317 vs. 0,270) a um custo computacional ~11x menor, e por atribuir todos os clientes a um segmento. Já o DBSCAN, encontrou apenas 3 clusters de qualidade inferior (silhouette 0,169) e classificou 135 clientes (3,2%) como ruído.

2.3 Escolha de k

O Silhouette Score isolado indicava k=2, enquanto o Elbow Method indicava k=5. Foi adotado k=5 por preservar a granularidade de negócio exigida pelo framework RFM clássico (Champions/Loyal/At Risk/New/Lost).

2.4 Validação

Estabilidade do K-Means testada com 10 seeds diferentes, com ARI médio de 0,966, indicando clusters praticamente idênticos independente da inicialização. Apresentou convergência em 17 iterações em média, bem abaixo do limite de 300. Redução dimensional via PCA preserva 94,1% da variância em 2D.

2.5 Limitações identificadas

A base cobre apenas 12 meses de um único mercado (Reino Unido), sem sazonalidade de anos anteriores nem dados de categoria de produto/canal, a segmentação reflete apenas comportamento transacional.

O RFM não distingue clientes atacadistas de varejo, um viés conhecido deste dataset. A escolha de k por Elbow é uma decisão de trade-off entre rigor estatístico (Silhouette) e utilidade de negócio.

3. Resultados e Insights

3.1 Resultados

Segmento	Clientes	% Base	Receita	% Receita	Recência média	Frequência média	Ticket médio anual
Champions	589	13,90%	£3,05M	50,60%	18 dias	12,7 pedidos	£5.184
At Risk	1.039	24,40%	£1,44M	23,80%	100 dias	3,3 pedidos	£1.383
Loyal Customers	730	17,20%	£972K	16,10%	13 dias	4,3 pedidos	£1.332
Lost	1.025	24,10%	£289K	4,80%	230 dias	1,3 pedidos	£282
New Customers	868	20,40%	£285K	4,70%	38 dias	1,5 pedidos	£328

Champions compram com frequência quase mensal (12,7 pedidos/ano) e têm ticket médio anual 3,7x maior que Loyal Customers, que é o segmento mais rentável por cliente. Concentrar apenas 14% da base em 50% da receita é tanto uma força (alta lucratividade por cliente) quanto um risco de concentração: a perda de uma fração desse grupo tem impacto desproporcional.

At Risk é o grupo de clientes que já compraram bem (ticket médio £1.383, mais alto que Loyal Customers) e com frequência razoável (3,3 pedidos), mas não compram há aproximadamente 100 dias, o dobro da recência de Loyal Customers. Isso não é um cliente de baixo valor, é um cliente de valor comprovado se afastando.

Loyal Customers têm o perfil mais saudável do ponto de vista de recência (13 dias, o menor de todos os grupos) mas frequência ainda moderada (4,3 pedidos/ano) e ticket relativamente baixo, é a base com maior potencial de crescimento pois já está engajada e recente.

New Customers têm recência razoável (38 dias) mas frequência muito baixa (1,5 pedidos), faz sentido tendo em vista que são clientes early-lifecycle que ainda não repetiram compra.

Lost é o grupo de menor prioridade: 230 dias de recência média e apenas 1,3 pedido/ano indicam clientes que provavelmente não vão reativar organicamente. Representam 24% da base mas menos de 5% da receita.

3.2 Oportunidade de negócio principal

A receita da empresa está polarizada entre muito engajado (Champions + Loyal = 31% da base, 66,7% da receita) e pouco engajado (At Risk + Lost+New = 69% da base, 33,3% da receita). Investir em mover clientes de At Risk e New Customers para Loyal tem mais retorno esperado do que tentar recuperar Lost.

3.3 Recomendações

- Cupom de reativação com prazo curto (7–14 dias) para clientes At Risk e comunicação personalizada por categoria de compra anterior.
- Programa VIP para clientes Champions. Acesso antecipado a lançamentos, atendimento dedicado e benefícios.
- Onboarding e incentivo à segunda compra para New Customers. E-mail/SMS nos primeiros 30 dias, cupom para a segunda compra e recomendação de produtos complementares ao primeiro pedido.

3.4 Viabilidade

Todas as recomendações usam canais e mecanismos já comuns em CRM de e-commerce (e-mail marketing, cupons, programas de fidelidade), sem necessidade de investimento em nova infraestrutura e são utilizados por diversos varejistas como prática comum de mercado.